FUXI-PDF / ORIGINAL DEMO / 01

Why mean-of-means fails

PARTITION A

[2, 4]

mean = 3

PARTITION B

[12]

mean = 12

(3 + 12) / 2 = 7.5 but (2 + 4 + 12) / 3 = 6

Original teaching example. No course materials used.

为什么“平均局部平均值”会算错?

这页在讲什么

问题不是加法算错了，而是局部平均值丢掉了它代表多少条记录。A 有两个观测值，B 只有一个；两组均值不能直接当成等重的两条观测。

1. 先算两组局部结果

A 的数据是 2、4，局部均值为 (2+4)/2=3。B 只有 12，局部均值为 12。若把 3 和 12 直接平均，得到 7.5，但这个动作把 B 的单条记录赋予了整组 A 的权重。

2. 回到原问题检查答案

原问题是三条记录的平均值，总和为 18、数量为 3，因此结果是 6。加机器或改变分区不应改变这个逻辑答案；问题在于中间表示没有保留计算所需信息。

3. 什么时候局部均值可以再平均?

各组大小相同，或明确按组内数量加权时才成立。一般分布式分组不能擅自假设组大小相同。下一页用可合并状态保留权重。

记住：分组方式会变，但全局答案不应因丢失组大小而改变。

FUXI-PDF / ORIGINAL DEMO / 02

Keep a mergeable state

PARTITION A

[2, 4]

(sum, count) = (6, 2)

PARTITION B

[12]

(sum, count) = (12, 1)

Merge: (6, 2) + (12, 1) = (18, 3). Finalize: 18 / 3 = 6.

Original teaching example. No course materials used.

保留 (sum, count)，最后再除一次

这页在讲什么

把平均值改写为能继续合并的状态：总和 sum 与数量 count。状态代表一个组贡献的全部信息，而不是已经丢掉权重的最终均值。

1. 每条记录变成状态

输入数值 x 先变成 (x,1)。A 合并为 (6,2)，B 合并为 (12,1)。即使先局部合并、再跨机器合并，状态的意义仍保持一致。

2. 合并只做分量相加

(s1,c1) 与 (s2,c2) 合并为 (s1+s2,c1+c2)，所以两组变成 (18,3)。在整数精确且不溢出的假设下，加法允许重新分组；浮点数舍入时还需注意精度。

3. 最后计算输出

只有所有贡献都合并完成后才计算 sum/count，得到 18/3=6。count=0 时按问题约定处理；涉及整数类型时，也要确认除法语义。部分结果应始终具有兼容的状态类型。

记住：先保存足够信息，再安全合并，最后才做不可逆的结果计算。